

MỤC LỤC

MỤC LỤC	i
DANH MỤC HÌNH ẢNH	iii
DANH MỤC BẢNG	iv
Chương 1 Giới thiệu	1
Chương 2 Kết hợp học tăng cường với học sâu	6
2.1 Học tăng cường kết hợp với học sâu	7
2.1.1 Học sâu	7
2.1.2 Mạng nơ-ron tích chập	10
2.1.3 Sử dụng mạng nơ-ron để xấp xỉ hàm	14
2.1.4 Học tăng cường kết hợp với xấp xỉ hàm	19
2.2 Kết hợp học tăng cường với học sâu vào bài toán tự động chơi game	21
2.2.1 “Deep Q-Network”	21
2.2.2 Kỹ thuật làm tăng tính ổn định	22
2.2.3 Vấn đề “đánh giá quá cao” của thuật toán “Q-learning” .	26
Chương 3 Kết quả thực nghiệm	31
3.1 Giới thiệu môi trường thực nghiệm	31
3.2 Các thiết lập thực nghiệm	31
3.3 Thuật toán “Q-learning”	33
3.4 Thuật toán “Double Q-learning”	36
3.5 Phân tích hàm giá trị hành động	39

Chương 4 Kết luận và hướng phát triển	42
TÀI LIỆU THAM KHẢO	43

DANH MỤC HÌNH ẢNH

1.1	Hình ảnh các game trên hệ máy Atari	3
2.1	Hình mô phỏng cách hoạt động của mô hình học sâu	9
2.2	Phép tính đặc trưng của CNN	12
2.3	Phép dịch chuyển bộ lọc của CNN	12
2.4	Tầng tích chập với ba bộ lọc	13
2.5	Cấu trúc mạng “Deep Q-Network”	23
2.6	Vấn đề đánh giá quá cao của thuật toán “Q-learning”	29
2.7	Cách giải quyết vấn đề đánh giá quá cao của thuật toán “Double Q-learning”	30
3.1	Đồ thị giá trị hành động trung bình và điểm thưởng trung bình	35
3.2	Đồ thị giá trị hành động trung bình và điểm thưởng trung bình của hai thuật toán	38
3.3	Hình ảnh một số “frame” của trò chơi <i>Seaquest</i>	40
3.4	Đồ thị giá trị hành động của một số trạng thái trong một lần chơi game	41

DANH MỤC BẢNG

3.1	Điểm thưởng nhận được của thuật toán “Q-learning”	36
3.2	Điểm thưởng nhận được của thuật toán “Double Q-learning” . .	36

Chương 1


Giới thiệu

Những năm gần đây, **học tăng cường** (Reinforcement learning) liên tục đạt được những thành tựu quan trọng trong lĩnh vực Trí tuệ nhân tạo (Artificial Intelligence). Những đóng góp nổi bật của phương pháp này bao gồm: tự động điều khiển robot di chuyển, điều khiển mô hình máy bay trực thăng, hệ thống chơi cờ vây... Trong số các thành tựu này, hệ thống chơi cờ vây với khả năng chiến thắng những kỳ thủ hàng đầu thế giới là một cột mốc quan trọng của lĩnh vực Trí tuệ nhân tạo. Dù vậy, học tăng cường không phải là một phương pháp mới được phát triển gần đây. Nền tảng lý thuyết của học tăng cường đã được xây dựng từ những năm 1980.

Được xây dựng nhằm mô phỏng quá trình học của con người, ý tưởng chính của học tăng cường là tìm cách lựa chọn hành động *tối ưu* để nhận được **nhều nhất giá trị điểm thưởng** (Reward). Giá trị điểm thưởng này có ý nghĩa tương tự cảm nhận của con người về môi trường. Khi một đứa trẻ bắt đầu “học” về thế giới xung quanh của mình, những cảm giác như đau đớn (ứng với điểm thưởng thấp) hay vui sướng (điểm thưởng cao) chính là mục tiêu cần tối ưu của việc học. Một điểm quan trọng của học tăng cường là nó được xây dựng với ít giả định nhất có thể về môi trường xung quanh. Hệ thống sử dụng học tăng cường (Agent) không cần biết cách thức hoạt động của môi trường để hoạt động. Ví dụ như để điều khiển robot tìm đường đi trong mê cung, hệ thống không cần biết mê cung được xây dựng thế nào hay kích thước là bao nhiêu. Việc hạn chế tối đa những ràng buộc về dữ liệu đầu vào của bài toán học tăng cường giúp cho phương pháp này có thể áp dụng vào nhiều bài toán thực tế.

Học tăng cường được xem là một nhánh trong lĩnh vực máy học ngoài hai nhánh: học có giám sát và học không có giám sát. Trong bài toán học có giám sát, dữ liệu thường được gán nhãn thủ công sẵn và việc chủ yếu của hệ thống là làm sao dự đoán chính xác các nhãn đó với dữ liệu mới. Các nhãn này có thể xem như là sự hướng dẫn trong quá trình học; tính đúng sai của việc học lúc này có thể được xác định dựa vào kết quả dự đoán của hệ thống và nhãn đúng của dữ liệu. Tiếp theo đối với những bài toán học không có giám sát, dữ liệu học thường không được gán nhãn nên công việc của việc học là phải tự tìm ra được cấu trúc “ẩn” bên dưới dữ liệu đó. Khác với hai loại bài toán vừa nêu, trong bài toán học tăng cường, hệ thống *không nhận được nhãn thực sự* (tức hành động tối ưu của tình huống hiện tại) mà chỉ nhận được điểm thưởng từ môi trường. Điểm thưởng lúc này chỉ thể hiện mức độ “tốt/xấu” của hành động vừa chọn chứ không nói lên hành động đó có phải là hành động tối ưu hay không. Điểm thưởng này thông thường rất thưa: ta có thể chỉ nhận được điểm thưởng có ý nghĩa (khác không) sau hàng nghìn hành động. Ngoài ra, giá trị điểm thưởng thường là không đơn định và rất nhiều: cùng một hành động tại cùng một trạng thái, ta có thể nhận được điểm thưởng khác nhau vào hai thời điểm khác nhau. Đây cũng chính là những khó khăn cơ bản của bài toán học tăng cường.

Các trò chơi điện tử thường hay có điểm số mà người chơi cần phải tối ưu hoá. Đặc điểm này trùng với yêu cầu của bài toán học tăng cường, vì vậy các trò chơi này cũng chính là những ứng dụng tự nhiên nhất của phương pháp học tăng cường. Trong luận văn này, chúng em áp dụng phương pháp học tăng cường nhằm xây dựng **hệ thống tự động chơi các game** trên hệ máy Atari. Dữ liệu đầu vào của hệ thống chỉ bao gồm các frame ảnh RGB cùng với điểm số hiện tại. Từ hình ảnh thô này, hệ thống cần tìm cách chơi sao cho điểm số cuối màn chơi (Episode) là lớn nhất có thể. Hệ thống hoàn toàn không biết quy luật của game trước khi bắt đầu quá trình học mà phải tự tìm hiểu quy luật và chiến thuật chơi tối ưu. Lý do luận văn sử dụng game của máy Atari là vì các game này có quy luật chơi tương đối đơn giản nhưng lại rất đa dạng. Mỗi màn chơi thường có độ dài vừa phải (từ 2 - 15 phút) và số hành động có ý nghĩa không quá nhiều (18 hành động). Ngoài ra, các trò chơi này có thể được giả lập trên máy vi tính với tốc độ cao, giúp quá trình học được tăng tốc.



Hình 1.1: Hình ảnh các game trên hệ máy Atari

Một số khó khăn trước mắt có thể thấy ở bài toán tự động chơi game bao gồm:

- Hệ thống không được cung cấp luật chơi của game. Chính vì thế nó cũng không thể biết được hành động nào nên làm hoặc không nên làm ứng với từng tình huống cụ thể.
- Dữ liệu đầu vào là hình ảnh RGB có kích thước 210×160 . Để học được một chiến thuật chơi đơn giản thì hệ thống cũng phải chơi “thử và sai” một số lượng lớn màn chơi (có thể lên đến 10000 frame). Vì vậy, lượng dữ liệu đầu vào cần phải xử lý là rất lớn.
- Các game có hình ảnh, nội dung rất khác nhau. Để có thể học cách chơi của nhiều game khác nhau thì thuật toán học phải mang tính tổng quát cao, không sử dụng các tính chất riêng biệt của từng game.
- Để đạt được điểm số cao (ngang hoặc hơn điểm số của con người) thì phải tìm được chiến thuật chơi mang tính lâu dài. Những phương pháp tham lam, lựa chọn hành động để đạt điểm tối đa trong tương lai gần thường

không tối ưu.

Một trong những tiếp cận đầu tiên cho bài toán tự động chơi game là cuộc thi AAAI General Game Playing được đề xuất từ năm 2005 bởi đại học Stanford. Trong cuộc thi này, các đội thi nhận được mô tả sơ bộ cho những game được sử dụng cuộc thi. Các mô hình chi tiết được thiết kế bên dưới các game này không được mô tả cho các đội chơi. Dựa vào những thông tin nhận được, các đội chơi phải thiết kế một mô hình tổng quát để có thể chơi những game này do trong cuộc thi họ sẽ được nhận ngẫu nhiên một trong những game đã được mô tả [4]. Đội thắng cuộc trong cuộc thi này đã sử dụng mô hình Monte Carlo Tree Search để tìm chiến lược chơi trong những game này.

Trong khoảng ba năm trở lại, tập những game trên hệ máy Atari 2600 trở nên phổ biến trong việc đánh giá khả năng của những phương pháp tiếp cận cho bài toán tự động chơi game. Những game này bao gồm nhiều thể loại khác nhau như: đối kháng, bắn súng... Với sự đa dạng trong cách chơi của những game Atari 2600, cũng như giao diện đơn giản làm cho chúng gây được sự chú ý lớn trong cộng đồng trí tuệ nhân tạo. Nhiều phương pháp đã được đề xuất liên quan tới bài toán tự động chơi game trên hệ máy Atari 2600. [1, 2] thực hiện chia những frame ảnh trong game thành nhiều phần; sau đó xây dựng cấu trúc cây và áp dụng mô hình học Bayesian để mô phỏng lại mô hình của "môi trường" đã được xây dựng trong các game này cho hệ thống. Tuy nhiên, hướng tiếp cận này giả định những phần ảnh lân cận là đủ thông tin để dự đoán những phần ảnh trung tâm, do đó không phù hợp trong một vài game Atari có sự tương tác phức tạp. [6] sử dụng mạng nơ-ron với cấu trúc nông để tạo ra một chính sách có thể tự động chơi một số game Atari. Phương pháp sử dụng thuật toán lập trình tiến hóa để tìm trọng số liên kết tối ưu trong mạng nơ-ron, khác với phương pháp truyền thống sử dụng lan truyền ngược. Mặc dù phương pháp này vượt qua điểm số của con người trong ba game Atari nhưng còn nhiều hạn chế. Một trong những hạn chế đó là đặc tính của lập trình tiến hóa hoạt động giống như một "hộp đen", nghĩa là chúng ta không thể dễ dàng quan sát, cũng như kiểm soát cách tìm kiếm những trọng số của mạng nơ-ron như đã làm với lan truyền ngược [10].

Trong những năm gần đây, học sâu đạt được nhiều bước đột phá trong nhiều

lĩnh vực như Thị giác máy tính (Computer Vision), Nhận diện giọng nói (Speech Recognition), ... Việc kết hợp giữa học sâu và học tăng cường đã dẫn đến một hướng tiếp cận mới cho bài toán tự động chơi game: học tăng cường sâu (Deep reinforcement learning) [9]. Với học sâu, ta có thể học được những đặc trưng cấp cao (high level features) từ hình ảnh thô mà không cần phải tự thiết kế đặc trưng bằng tay (hand-designed features). Khi kết hợp với học tăng cường, ta có một hình “**End-to-end**”: việc học đặc trưng và học chiến thuật chơi được liên kết chặt chẽ với nhau. Trong luận văn này, chúng em thực hiện việc cài đặt lại phương pháp học tăng cường sâu và thử nghiệm mô hình với những tham số khác nhau. Cùng với đó, luận văn thử nghiệm kỹ thuật học chuyển tiếp (Transfer learning) nhằm giảm thời gian huấn luyện cho nhiều game.

Chương 2

Kết hợp học tăng cường với học sâu

Những thành công gần đây của học sâu (Deep learning) trong các bài toán như xử lý ngôn ngữ tự nhiên, nhận diện đối tượng trong ảnh... đặt ra vấn đề: liệu các kỹ thuật trong học sâu có thể áp dụng vào học tăng cường? Để trả lời câu hỏi đó, chương này trình bày về hướng tiếp cận kết hợp học sâu với học tăng cường để áp dụng vào bài toán “Tự động chơi game”. Hướng tiếp cận mới mẻ này của lĩnh vực học tăng cường này mang tên “Học tăng cường sâu” (Deep reinforcement learning)

Chương này trình bày hai phần:

- Nguyên nhân cần sử dụng học sâu và kiến thức cơ bản về học sâu
- Áp dụng học tăng cường sâu vào bài toán “Tự động chơi game”

2.1 Học tăng cường kết hợp với học sâu

2.1.1 Học sâu

Lý do cần áp dụng học sâu

Những thuật toán học tăng cường được trình bày trong chương trước đều tìm chính sách tối ưu dựa vào hàm giá trị. Việc tính **đúng** và **nhANH** hàm giá trị ảnh hưởng rất nhiều đến kết quả của bài toán. Các thuật toán học tăng cường cổ điển như “Monte Carlo” (MC) hay “Temporal-Difference” (TD) đều đã được chứng minh là luôn hội tụ trong những điều kiện nhất định [11]. Ngoài ra, khi áp dụng vào các bài toán kinh điển của học tăng cường thì các thuật toán này đều hội tụ khá nhanh.

Tuy nhiên, với những bài toán thực tế với số trạng thái rất lớn thì việc lưu véc-tơ hàm giá trị trạng thái v_π (hoặc ma trận hàm giá trị hành động q_π) là việc không thể. Ví dụ như “frame hình” của bài toán tự động chơi game có kích thước $210 \times 160 \times 3 = 100800$ điểm ảnh; mỗi điểm ảnh có giá trị trong khoảng $[0, 127]$ nên số trạng thái có thể có lên đến 128^{100800} . Vì vậy, việc lưu trữ hàm giá trị dưới dạng bảng là không khả thi về mặt bộ nhớ. Còn về mặt tốc độ tính toán thì các thuật toán học tăng cường trên đều tính hàm giá trị *rời rạc* cho từng trạng thái. Với số trạng thái quá lớn như trên thì ta không thể duyệt lần lượt từng trạng thái để tính được.

Những lý do trên dẫn đến việc sử dụng một phương pháp xấp xỉ hàm là bắt buộc cho các bài toán học tăng cường với số trạng thái lớn. Một trong những tiếp cận rất tự nhiên đó là sử dụng các mô hình học có giám sát như là một phương pháp xấp xỉ hàm giá trị. Đặc biệt, với những đột phá gần đây của học sâu trong lĩnh vực xử lý ảnh, video... thì việc áp dụng các mô hình phổ biến của học sâu vào bài toán tự động chơi game là đầy hứa hẹn.

Giới thiệu học sâu

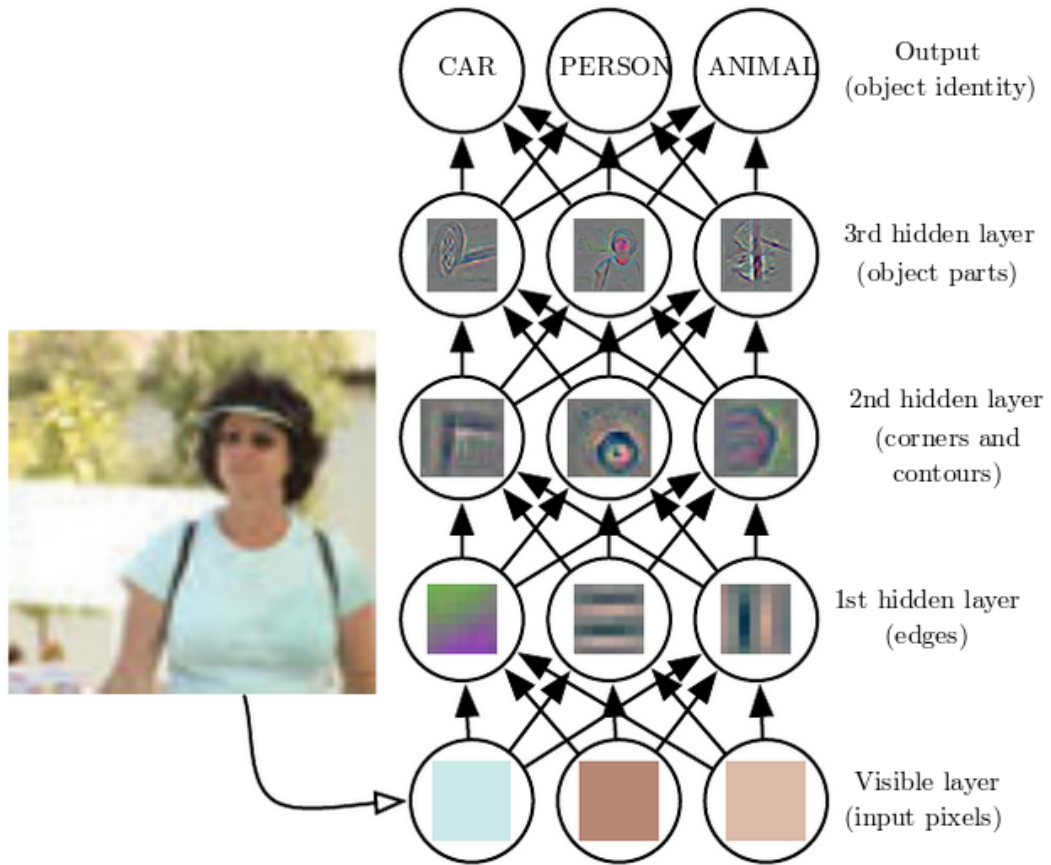
Các mô hình truyền thống trong lĩnh vực máy học như “Linear regression”, “Bayesian learning”... thông thường đều hoạt động trên các đặc trưng được *rút*

trích một cách thủ công (hand-designed features). Với dữ liệu thô thu thập được từ thực tế, các nhà khoa học xây dựng các phương pháp rút trích ra những “thông tin hữu ích” (thường được gọi là đặc trưng) để cung cấp cho các mô hình máy học. Kết quả nhận được từ các mô hình này phụ thuộc rất lớn vào cách biểu diễn dữ liệu. Ví dụ như trong bài toán nhận diện người nói từ một đoạn âm thanh, các đặc trưng có thể bao gồm: độ lớn âm thanh, tần số trung bình của đoạn âm,... Nếu các đặc trưng này không đủ “mạnh” (như có hai người nói đoạn âm thanh nhưng lại có chung độ lớn, tần số...) thì các mô hình học sẽ không thể phân biệt.

Để giải quyết vấn đề thiết kế đặc trưng, các mô hình máy học thuộc loại “Học biểu diễn” (*Representation learning*) ra đời. Các mô hình này có khả năng tự động học luôn các đặc trưng cần thiết cho quá trình phân tích dữ liệu. Nhờ vậy, các mô hình này có thể áp dụng được dễ dàng hơn vào các bài toán thực tế mà không cần con người phải can thiệp. Tuy nhiên, các đặc trưng cần thiết lại có thể rất phức tạp. Việc học ra các đặc trưng này có thể khó ngang với việc giải bài toán gốc. Ví dụ như trong bài toán nhận diện người nói trên, ta có thể sử dụng thông tin về giọng địa phương của người nói (accent). Đặc trưng này rất trừu tượng, không dễ phân tích bằng máy tính mặc dù con người có thể nhận biết một cách khá dễ dàng. Vì vậy, nếu các đặc trưng cần thiết quá khó để học thì các mô hình máy học thuộc loại “Học biểu diễn” cũng không thể cho kết quả tốt.

Học sâu (Deep learning) được ra đời nhằm giải quyết các vấn đề trên. Học sâu là một nhánh của “Học biểu diễn” nên vẫn có thể tự động học ra các đặc trưng hữu ích. Học sâu được thiết kế để học ra các đặc trưng có quan hệ với nhau theo nhiều tầng (layer). Các đặc trưng ở tầng phía sau được xây dựng dựa vào các đặc trưng ở tầng phía trước. Các tầng đầu tiên bao gồm những đặc trưng đơn giản và các tầng tiếp theo ngày càng trừu tượng, ngày càng phức tạp hơn. Mỗi tầng chỉ cần học cách xây dựng đặc trưng từ những đặc trưng ở tầng phía trước (đã có sẵn độ trừu tượng nhất định) thay vì học từ dữ liệu thô ban đầu; điều này giúp cho học sâu có khả năng học được những đặc trưng rất phức tạp.

Một trong những mô hình học sâu phổ biến nhất và cũng cho kết quả rất



Hình 2.1: Hình mô phỏng cách hoạt động của mô hình học sâu cho bài toán nhận diện đối tượng trong ảnh. Dữ liệu đầu vào là hình ảnh RGB chứa đối tượng cần xác định. Tầng đầu tiên của mô hình là tầng “input” tiếp nhận thông tin này dưới dạng ma trận số. Các tầng tiếp theo ngoại trừ tầng cuối cùng được gọi là tầng ẩn “hidden layer” vì đặc trưng học được tại đây con người không quan sát được. Các tầng ẩn học các đặc trưng ngày càng trừu tượng dựa vào đặc trưng ở tầng phía trước. Tầng ẩn đầu tiên học được các đặc trưng về cạnh bằng cách so sánh độ sáng giữa các điểm ảnh gần nhau. Tầng ẩn thứ hai học được các đặc trưng về đường cong bằng cách tổng hợp đặc trưng về cạnh ở tầng trước đó. Tầng ẩn thứ ba học được các đặc trưng về bộ phận của đồ vật như khuôn mặt, bánh xe... dựa vào các đặc trưng về đường cong ở tầng trước. Tầng cuối cùng được gọi là tầng “output” có nhiệm vụ tìm kiếm các bộ phận và trả về lớp đối tượng tương ứng. Bằng cách học đặc trưng ngày càng trừu tượng hơn, các mô hình học sâu có khả năng tự động học được các đặc trưng từ đơn giản đến phức tạp; tất cả đều nhằm hỗ trợ cho quá trình phân lớp dữ liệu (hình được chỉnh sửa từ [3])

tốt với dữ liệu ảnh đó là mạng nơ-ron tích chập (Convolutional Networks). Với bài toán tự động chơi game, dữ liệu hệ thống nhận được từ môi trường là ảnh RGB. Chính vì vậy, mạng nơ-ron tích chập là một mô hình rất phù hợp để kết hợp với các thuật toán học tăng cường.

2.1.2 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập (Convolutional Networks - CNN) là một mô hình học sâu được áp dụng rộng rãi trong các bài toán liên quan đến ảnh, video hoặc âm thanh... CNN được thiết kế để tận dụng thông tin về không gian (spatial structures) của các loại dữ liệu nêu trên. Ví dụ như trong bài toán nhận diện mặt người trong ảnh, thông tin về vị trí của mắt, mũi, miệng... là rất quan trọng. Nếu ta coi các điểm ảnh đều có ý nghĩa tương tự nhau thì ta đã bỏ quên thông tin về vị trí của những đặc trưng này. Ví dụ như khi ta tìm được hai mắt và miệng trong bức ảnh, ta có thể xác định vị trí tương đối của mũi là nằm ở giữa hai đặc trưng này. Trong ví dụ trên, nếu ta áp dụng các mô hình không quan tâm đến loại dữ liệu (coi từng thuộc tính dữ liệu đầu vào là độc lập) thì ta sẽ không tận dụng được thông tin về không gian trong đó.

Để tận dụng thông tin về không gian trong dữ liệu ảnh, CNN được thiết kế để học các đặc trưng trên một vùng nhỏ của ảnh. Các đặc trưng này được lưu trữ dưới dạng những bộ lọc (filter) thường có kích thước nhỏ hơn nhiều so với kích thước ảnh gốc. Các đặc trưng sau khi được học được áp dụng trên toàn bộ ảnh gốc để kiểm tra xem vị trí nào của ảnh xuất hiện đặc trưng này. CNN thực hiện phép kiểm tra này bằng cách “trượt” các bộ lọc này trên toàn bộ ảnh gốc. Phép “trượt” được thực hiện lần lượt từ trái qua phải và từ trên xuống dưới. Một cách tổng quát, phép “trượt” này có thể di chuyển không đồng đều theo hai chiều: ta có thể chỉ di chuyển qua phải một điểm ảnh nhưng lại di chuyển xuống dưới hai điểm ảnh. Tại mỗi vị trí, bộ lọc có nhiệm vụ kiểm tra thử đặc trưng được học có xuất hiện (hoặc mức độ rõ ràng của đặc trưng - đặc trưng xuất hiện nhiều hay ít) tại vị trí này không. Kết quả của phép kiểm tra này được lưu trữ lại dưới dạng một “bức ảnh” nhỏ hơn; giá trị mỗi “điểm ảnh” lúc này chính là kết quả của phép kiểm tra đặc trưng của bộ lọc. Do phép “trượt” được thực hiện theo thứ tự được nêu ở trên, các “điểm ảnh” kết quả vẫn mang thông tin

tương đối về vị trí: “điểm ảnh” bên trái ứng với kết quả của vùng nằm bên trái trong ảnh gốc và tương tự với điểm ảnh bên phải.


Phép “kiểm tra” đặc trưng của bộ lọc được thực hiện thông qua phép toán **tích chập** (convolution):

$$a_{i,j} = \sigma \left(b + \sum_{u=0}^{height} \sum_{v=0}^{width} w_{u,v} x_{i+u,j+v} \right) \quad (2.1)$$


Trong đó:

- $a_{i,j}$ là kết quả của phép kiểm tra tại vùng có góc trái trên là i, j trong ảnh gốc.
- b là số thực gọi là “bias” của bộ lọc.
- $width, height$ lần lượt là chiều rộng và chiều cao của bộ lọc (5×5 trong hình (2.2)).
- w là ma trận trọng số có kích thước $height \times width$ của bộ lọc. $w_{u,v}$ là thành phần dòng u cột v của ma trận.
- $x_{i+u,j+v}$ là giá trị điểm ảnh đầu vào tại vị trí dòng $i + u$ và cột $j + v$.
- σ là một hàm phi tuyến được gọi là hàm kích hoạt (activation function).


Phép toán tích chập này chỉ đơn giản là một tổng gồm các tích của trọng số và giá trị điểm ảnh. Hàm kích hoạt sau đó nhận giá trị tổng của phép tích chập để thực hiện phép biến đổi phi tuyến tính; nhờ có hàm kích hoạt, bộ lọc có thể học được những đặc trưng phi tuyến tính. Một trong những hàm phi tuyến hay được áp dụng đó là hàm “Rectified linear”: $\sigma(x) = \max(0, x)$. Công thức tích chập trên chứa hai thành phần cần được “học” đó là “bias” b và ma trận trọng số w . Hai thành phần này lưu trữ thông tin về đặc trưng mà bộ lọc học được. Một trong những đặc điểm quan trọng nhất là việc ma trận trọng số w và “bias” b được sử dụng chung cho việc “kiểm tra” đặc trưng tại mọi vị trí của ảnh gốc. Nhờ việc sử dụng chung ma trận trọng số và “bias” này, số lượng trọng số phải học của CNN được giảm đi rất nhiều. Cụ thể hơn, với ảnh gốc kích thước



Hình 2.2: Hình mô tả phép “kiểm tra” đặc trưng của bộ lọc có kích thước 5×5 tại vị trí đầu tiên (góc trái trên) của ảnh đầu vào. Kết quả của phép “kiểm tra” này được lưu lại thành một “điểm ảnh” trong “bức ảnh kết quả”. Lưu ý ảnh đầu vào trong ví dụ ở đây có kích thước 28×28 . Do bộ lọc chỉ kiểm tra những vùng nằm hoàn toàn trong ảnh nên kích thước của “bức ảnh” đầu ra là 24×24



Hình 2.3: Bộ lọc được trượt sang một điểm ảnh về phía bên phải để kiểm tra vùng cục bộ 5×5 bên cạnh. Kết quả của phép “kiểm tra” này được lưu lại thành một “điểm ảnh” bên phải của kết quả của vùng cục bộ trước đó. Thực hiện lần lượt quá trình “trượt” này đến hết ảnh ta sẽ có “bức ảnh kết quả” cuối cùng. “Bức ảnh kết quả” này mang thông tin về một đặc trưng cụ thể tại những vùng cục bộ liên tiếp nhau của ảnh gốc.



Hình 2.4: Hình mô tả tầng tích chập với ba bộ lọc học đặc trưng từ ảnh đầu vào. Mỗi bộ lọc lúc này học một bộ trọng số w và giá trị “bias” b khác nhau. Do các bộ lọc có cùng kích thước (5×5) nên “bức hình” kết quả cũng có cùng kích thước. Ta coi mỗi “bức hình” kết quả như một kênh (channel) khác nhau của bức hình và ghép chúng lại thành một bức hình lớn hơn gồm ba kênh. Các kênh này cũng giống như ba kênh màu khác nhau của ảnh RGB.

$28 \times 28 = 784$ như trong hình (2.2), nếu áp dụng mạng nơ-ron truyền thẳng thông thường để học đặc trưng từ toàn bộ ảnh, số lượng trọng số sẽ lên đến 784 cho một đặc trưng. Trong khi đó, CNN chỉ gồm khoảng $5 \times 5 = 25$ trọng số cần học.

Một bộ lọc của CNN chỉ học được một đặc trưng cụ thể. Tuy nhiên trong bài toán thực tế, ta cần nhiều đặc trưng khác nhau trên ảnh. Ví dụ như để nhận diện khuôn mặt trên ảnh, ta cần đặc trưng về mắt, miệng... Để học được nhiều đặc trưng khác nhau với CNN, ta chỉ việc thiết kế thêm nhiều bộ lọc học đặc trưng song song với nhau từ ảnh gốc. Với mỗi bộ lọc, ta cần học một ma trận trọng số và giá trị “bias” khác nhau. Ta gọi tập hợp các bộ lọc này là một tầng tích chập (convolution layer). Hình (2.4) mô tả tầng tích chập với ba bộ lọc.

CNN là một mô hình học sâu. Vì vậy để học được những đặc trưng có tính trừu tượng cao, CNN áp dụng phương pháp tổng hợp đặc trưng phức tạp từ những đặc trưng đơn giản hơn. Để tổng hợp đặc trưng, ta chỉ việc coi “bức hình kết quả” như là bức ảnh đầu vào và thêm tầng tích chập mới học đặc trưng từ bức hình này. Do kết quả của tầng tích chập trước mang thông tin về đặc trưng

được học bởi các bộ lọc, tăng tích chập tiếp theo thực hiện việc học từ các đặc trưng đã học ở tầng trước. Nhờ vậy, việc thêm vào các tầng tích chập tiếp theo sẽ giúp mô hình học được những đặc trưng ngày càng phức tạp hơn.

Phần tiếp theo sẽ trình bày cách sử dụng CNN như là một công cụ xấp xỉ hàm hỗ trợ cho các thuật toán học tăng cường. Do có khả năng học đặc trưng tự động, ta có thể thiết kế một công cụ xấp xỉ hàm “đa năng”: vừa học đặc trưng từ hình ảnh, vừa xấp xỉ hàm mong muốn từ những hình ảnh đó.

2.1.3 Sử dụng mạng nơ-ron để xấp xỉ hàm

Việc sử dụng mạng nơ-ron tích chập (hoặc mạng nơ-ron nói chung) để xấp xỉ hàm giá trị mang lại ba lợi ích quan trọng:

- Mạng nơ-ron có khả năng học được những đặc trưng phức tạp từ dữ liệu thô.
- Mạng nơ-ron có thể xấp xỉ hàm giá trị phức tạp.
- Mạng nơ-ron có thể tổng quát hoá từ trạng thái đã biết sang trạng thái chưa biết.

Mạng nơ-ron là một mô hình học sâu nên có thể học được những đặc trưng phức tạp từ dữ liệu thô như đã nói ở phần trên. Cụ thể hơn trong bài toán tự động chơi game, ta có thể đưa dữ liệu đầu vào là các “frame hình” RGB thẳng vào “input” của mạng nơ-ron để tính ra giá trị tương ứng. Nhờ vậy, ta không cần phải thiết kế các đặc trưng bằng tay để biểu diễn cho từng trạng thái của game. Ngoài ra, do quá trình học đặc trưng là hoàn toàn tự động, thuật toán học tăng cường lúc này có thể áp dụng cho bất kỳ game nào mà không cần phải thay đổi cách rút trích đặc trưng. Với một mô hình cố định lúc này, ta có thể học chơi được nhiều game. Đây cũng chính là mục đích của bài toán tự động chơi game: xây dựng mô hình có khả năng tự động học chơi *tốt* nhiều game chứ không chỉ chơi “hoàn hảo” một game.

Với bài toán tự động chơi game, giá trị của một trạng thái bất kỳ rất khó xác định do một màn game thường rất dài. Vì thế, hàm giá trị của bài toán này là một hàm phi tuyến phức tạp và không liên tục. Công cụ xấp xỉ hàm giá trị

phải có khả năng xấp xỉ những hàm phức tạp như vậy thì thuật toán học tăng cường mới đạt được hiệu quả. Với cách nhìn nhận mạng nơ-ron như là một công cụ xấp xỉ hàm, ta có thể thấy mạng nơ-ron rất linh hoạt với khả năng xấp xỉ hàm đích bất kỳ.

Một tính chất quan trọng khác của mạng nơ-ron chính là khả năng tổng quát hoá (generalization) từ trạng thái đã biết sang trạng thái chưa biết. Nhờ đặc điểm này mà quá trình học tăng cường được tăng tốc đáng kể. Thay vì phải duyệt qua từng trạng thái (thậm chí phải duyệt nhiều lần) để tính hàm giá trị tại đó, mạng nơ-ron có khả năng “dự đoán” giá trị của một trạng thái chưa từng thấy dựa vào những trạng thái đã thấy. Như trong bài toán tự động chơi game thì các “frame hình” liên tiếp thường rất giống nhau và các trạng thái này thường cũng có giá trị tương đương nhau. Vì vậy, khi học xong cách chơi một game nào đó, thuật toán học tăng cường vẫn hoạt động tốt trong quá trình kiểm thử khi gặp những tình huống game chưa từng thấy trong lúc huấn luyện.

Các thuật toán học tăng cường ở chương 2 đều lưu hàm giá trị dưới dạng bảng (lookup table). Để sử dụng mạng nơ-ron như một công cụ xấp xỉ hàm, lúc này ta coi hàm giá trị là một hàm có tham số (parameterized function) và đi tìm các tham số này:

$$\hat{v}(s; \theta) \approx v_{\pi}(s) \quad (2.2)$$

$$\hat{q}(s, a; \theta) \approx q_{\pi}(s, a) \quad (2.3)$$

θ là bộ trọng số của mạng nơ-ron mà ta cần học. Để học được bộ trọng số xấp xỉ tốt hàm đích ($v_{\pi}(s)$ hoặc $q_{\pi}(s, a)$), ta cung cấp các mẫu dữ liệu (data sample). Mỗi mẫu bao gồm dữ liệu đầu vào của mạng nơ-ron (tức trạng thái s hoặc bộ trạng thái, hành động s, a) cùng với giá trị đích mong muốn (tức $v_{\pi}(s)$ hoặc $q_{\pi}(s, a)$). Khi ta cung cấp đủ nhiều mẫu dữ liệu cho mạng nơ-ron, các bộ tham số sẽ được thay đổi để mạng xấp xỉ được hàm đích mong muốn. Số lượng mẫu dữ liệu càng lớn thì mạng nơ-ron càng “thấy” được nhiều giá trị tại nhiều vị trí khác nhau của hàm đích hơn, khi đó mạng nơ-ron càng có khả năng xấp xỉ hàm đích tốt hơn. Để xét xem mạng nơ-ron có xấp xỉ tốt hàm đích hay chưa, ta có thể tính độ “khác biệt” của giá trị đích với giá trị xấp xỉ trên cả không gian đầu

vào:

$$J(\theta) = \mathbb{E}_{s \sim \pi}[(v_\pi(s) - \hat{v}(s; \theta))^2] \quad (2.4)$$

$$J(\theta) = \mathbb{E}_{s, a \sim \pi}[(q_\pi(s, a) - \hat{q}(s, a; \theta))^2] \quad (2.5)$$

Kỳ vọng $\mathbb{E}_{s \sim \pi}$ ý chỉ kỳ vọng với biến ngẫu nhiên là trạng thái s được lấy từ phân bố do chính sách π tạo nên. Ví dụ như ta cần xấp xỉ hàm giá trị của một chính sách chỉ luôn “đi qua trái” thì s sẽ là những trạng thái mà khi đi theo chính sách này, ta có thể gặp được s . Trong khi đó nếu chính sách đang xét là “đứng yên” (không thay đổi trạng thái) thì s chỉ có thể có một trạng thái duy nhất đó là trạng thái bắt đầu. Giá trị nằm trong kỳ vọng là độ lỗi bình phương giữa giá trị xấp xỉ và giá trị đích. Với hàm lỗi bình phương, có thể thấy khi $J(\theta)$ càng nhỏ thì bộ trọng số θ giúp cho mạng nơ-ron xấp xỉ hàm đích càng tốt. Lý do chính ta chọn độ lỗi bình phương (ví dụ thay vì độ lỗi theo trị tuyệt đối) là vì việc tính toán (như đạo hàm) trên hàm bình phương khá dễ dàng.

Lưu ý là ở đây, hàm lỗi $J(\theta)$ là hàm theo θ ; tức là lúc này, ta cố định bộ trọng số θ để tìm ra “sai số” mà bộ trọng số này gây ra. Nếu ta có hai bộ trọng số θ_1 và θ_2 , ta có thể so sánh khả năng xấp xỉ hàm đích của chúng bằng cách so sánh giá trị $J(\theta_1)$ và $J(\theta_2)$ tương ứng.

Tuy nhiên ta không thể tính độ lỗi trên mọi điểm dữ liệu đầu vào theo công thức (2.4) và (2.5) được vì số lượng trạng thái là rất lớn. Vậy ta có thể xấp xỉ giá trị $J(\theta)$ bằng cách chỉ xét độ lỗi trên một “tập huấn luyện” (hay còn gọi là “Batch”) các trạng thái mà ta biết được giá trị đích. Khi đó, kỳ vọng $\mathbb{E}_{s \sim \pi}$ được thay thế bằng giá trị trung bình độ lỗi trên từng mẫu dữ liệu của “batch”:

$$J(\theta) = \frac{1}{N} \sum_{i=1}^N (v_\pi(S_i) - \hat{v}(S_i; \theta))^2 \quad (2.6)$$

$$J(\theta) = \frac{1}{N} \sum_{i=1}^N (q_\pi(S_i, A_i) - \hat{q}(S_i, A_i; \theta))^2 \quad (2.7)$$

Trong đó:

- N là số mẫu dữ liệu trong “batch”.

- S_i , A_i tương ứng là trạng thái và hành động của mẫu dữ liệu thứ i của “batch”.

Với một tập huấn luyện, ta mong muốn tìm được bộ trọng số giúp cho mạng nơ-ron xấp xỉ tốt hàm đích trên các mẫu dữ liệu thuộc tập huấn luyện này. Một thuật toán đơn giản và hay được sử dụng để tìm bộ trọng số này đó là “Batch Gradient Descent” (BGD). Để cực tiểu hoá hàm $J(\theta)$, thuật toán BGD thực hiện lặp lại nhiều “bước đi” nhỏ để thay đổi bộ trọng số θ dần dần; mỗi bước đi sẽ giúp cho hàm $J(\theta)$ giảm đi một ít. Để chọn “hướng đi” (tức cách cập nhật θ) thì BGD sẽ “nhìn” xung quanh vị trí hiện tại và đi theo hướng nào giúp giảm $J(\theta)$ nhiều nhất có thể. Hướng đi này chính là ngược hướng véc-tơ đạo hàm riêng (tức “gradient”) của hàm $J(\theta)$ tại θ . Như vậy, thuật toán BGD thực hiện lặp lại nhiều lần việc cập nhật bộ trọng số θ theo công thức:

$$\theta_{t+1} = \theta_t - \alpha \nabla_{\theta} J(\theta) \quad (2.8)$$

Trong đó:

- θ_t là bộ trọng số tại bước thứ t .
- α là hệ số học (learning rate); giá trị này dùng để điều khiển độ lớn của “bước đi”.
- $\nabla_{\theta} J(\theta)$ là véc-tơ đạo hàm riêng của hàm $J(\theta)$ tại vị trí θ

Do ta chỉ “nhìn” cục bộ tại vị trí hiện tại nên nếu ta đi một bước quá dài (hệ số học α lớn) thì giá trị hàm lỗi J tại điểm đến sẽ không chắc là sẽ giảm; còn nếu bước đi quá ngắn thì mỗi bước chỉ giảm J một ít, khi đó ta sẽ tốn rất nhiều thời gian để J đạt giá trị cực tiểu.

Một thuật toán cải tiến của BGD hay được sử dụng đó là “Stochastic Gradient Descent” (SGD). Điểm yếu của thuật toán BGD là ta cần phải tính véc-tơ đạo hàm riêng cho **tất cả** các mẫu trong “batch” để cập nhật được một lần cho bộ trọng số. Thuật toán SGD khắc phục điểm yếu này bằng cách chọn ngẫu nhiên một số mẫu dữ liệu trong “batch” (gọi là “mini-batch”), tính véc-tơ đạo hàm riêng trung bình trên “mini-batch” này và thực hiện cập nhật bộ trọng số. Lúc

này, véc-tơ đạo hàm riêng trung bình trên “mini-batch” có thể coi là một xấp xỉ của véc-tơ đạo hàm riêng trung bình trên toàn bộ tập huấn luyện. Do véc-tơ này chỉ tính trên “mini-batch” nên khi cập nhật, giá trị $J(\theta)$ có thể tăng. Tuy nhiên, khi cập nhật nhiều lần thì xu hướng chung là hàm lỗi $J(\theta)$ sẽ giảm. Khi tập huấn luyện càng lớn thì lợi thế của thuật toán SGD càng rõ. Với tập huấn luyện gồm 1000 mẫu thì thuật toán BGD chỉ cập nhật trọng số được **một** lần sau khi duyệt qua hết dữ liệu; trong khi đó, thuật toán SGD với kích thước “mini-batch” là 10 có thể cập nhật được 100 lần. Kích thước của “mini-batch” lúc này ảnh hưởng đến độ chính xác của véc-tơ đạo hàm riêng của $J(\theta)$. Nếu kích thước quá nhỏ thì véc-tơ đạo hàm riêng trung bình trên “mini-batch” sẽ không xấp xỉ tốt véc-tơ đạo hàm riêng trung bình trên toàn bộ tập huấn luyện. Nếu kích thước quá lớn thì lợi thế về tốc độ của SGD so với BGD sẽ không còn cao.

Như đã đề cập ở chương 2, để cải tiến chính sách khi không có đầy đủ thông tin về môi trường (tức không có các ma trận của MDP) ta cần xấp xỉ q_π thay vì v_π . Áp dụng thuật toán SGD để cực tiểu hoá hàm lỗi (2.7), công thức cập nhật bộ trọng số tại thời điểm t có dạng:

$$\theta_{t+1} = \theta_t - \Delta\theta_t \quad (2.9)$$

$$= \theta_t - \alpha \nabla_{\theta_t} J(\theta_t) \quad (2.10)$$

$$= \theta_t - \alpha \nabla_{\theta_t} \left(\frac{1}{B} \sum_{i=1}^B (q_\pi(S_i, A_i) - \hat{q}(S_i, A_i; \theta_t))^2 \right) \quad (2.11)$$

$$= \theta_t - \alpha \frac{1}{B} \sum_{i=1}^B (q_\pi(S_i, A_i) - \hat{q}(S_i, A_i; \theta_t)) \nabla_{\theta_t} \hat{q}(S_i, A_i; \theta_t) \quad (2.12)$$

Ở đây:

- $\Delta\theta$ là giá trị cập nhật tại cho một “mini-batch”.
- B là kích thước của “mini-batch”
- $q_\pi(S_i, A_i)$ là giá trị **thật sự** của hành động A_i tại trạng thái S_i khi thực hiện theo chính sách π
- $\hat{q}(S_i, A_i; \theta_t)$ là giá trị **xấp xỉ** của hành động A_i tại trạng thái S_i khi thực

hiện theo chính sách π

- $\nabla_{\theta_t} \hat{q}(S_i, A_i; \theta_t)$ là véc-tơ đạo hàm riêng của hàm \hat{q} tại trạng thái S_i và hành động A_i

Công thức trên bao gồm một tổng các số hạng có thể được tính riêng lẻ cho từng mẫu dữ liệu. Vậy để đơn giản hoá công thức, ta viết lại công thức trên cho duy nhất một mẫu dữ liệu; khi cần thiết lập công thức tổng quát cho một “mini-batch”, ta chỉ việc tính giá trị trung bình của nhiều mẫu. Lúc này, công thức mới sẽ ứng với trường hợp kích thước “mini-batch” đúng bằng một nên ta có thể bỏ chỉ số i của từng mẫu dữ liệu:

$$\theta_{t+1} = \theta_t - \alpha(q_\pi(S, A) - \hat{q}(S, A; \theta_t)) \nabla_{\theta_t} \hat{q}(S, A; \theta_t) \quad (2.13)$$

2.1.4 Học tăng cường kết hợp với xấp xỉ hàm

Áp dụng thuật toán SGD để tối ưu hàm lỗi J theo công thức (2.12) thì ta sẽ cực tiểu hoá được độ khác biệt giữa hai hàm q_π và \hat{q} . Tuy nhiên, giá trị đích thực sự mà ta mong muốn là $q_\pi(s, a)$ ta không biết được mà chỉ có một số **mẫu** S_t, A_t khi tương tác với môi trường. Các thuật toán học tăng cường chính là kỹ thuật giúp ta có được một ước lượng đơn giản của giá trị đích này. Như ở chương 2, ta có hai thuật toán để ước lượng hàm giá trị: thuật toán “Monte-Carlo” (MC) và thuật toán “Temporal Difference” (TD).

Với thuật toán MC, ta chỉ việc thay thế $q_\pi(s, a)$ bằng một ước lượng không chệch của giá trị này. Theo định nghĩa:

$$q_\pi(s, a) = \mathbb{E}_\pi [R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-t-1} R_T \mid S_t = s, A_t = a] \quad (2.14)$$

Vậy ta có thể lấy $R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-t-1} R_T$ làm một ước lượng cho $q_\pi(s, a)$. Giá trị này có thể dễ dàng có được bằng cách cho hệ thống tương tác với môi trường đến khi kết thúc một màn (tức một “episode”). Sau đó với mỗi trạng thái S_t của “episode”, ta chỉ cần tính tổng điểm thưởng đến cuối “episode” để có giá trị ước lượng mong muốn. Đây là một ước lượng không chệch do kỳ vọng của biểu thức này bằng đúng $q_\pi(s, a)$. Vậy công thức cập nhật bộ trọng số trong

(2.13) được thay bằng:

$$\theta_{t+1} = \theta_t - \alpha(G_t - \hat{q}(S, A; \theta_t)) \nabla_{\theta_t} \hat{q}(S, A; \theta_t) \quad (2.15)$$

G_t ở đây là tổng điểm thưởng (tức “Returns”) nhận được khi thực hiện hành động A tại trạng thái S . Kết hợp thuật toán MC với thuật toán SGD để cực tiểu hoá hàm lỗi của mạng nơ-ron, ta có được một thuật toán học tăng cường kết hợp học sâu hoàn chỉnh để giải các bài toán có số trạng thái lớn.

Với ý tưởng tương tự, để sử dụng mạng nơ-ron để xấp xỉ hàm giá trị cho thuật toán “Q-learning”, ta sử dụng tổng điểm thưởng được “bootstrap” để ước lượng $q_\pi(s, a)$. Cụ thể hơn, ta sẽ thay thế giá trị $q_\pi(s, a)$ trong công thức (2.14) bằng $R_{t+1} + \gamma \max_a \hat{q}(S_{t+1}, a; \theta)$. Có thể thấy rằng, giá trị “bootstrap” này là một ước lượng chệch của $q_\pi(s, a)$. Tuy vậy, ước lượng này chỉ gồm tổng của hai số hạng R_{t+1} và $\gamma \max_a \hat{q}(S_{t+1}, a; \theta)$ nên có phương sai thấp hơn nhiều so với ước lượng của MC (gồm tổng của nhiều số hạng R_{t+1}, R_{t+2}, \dots). Đây cũng chính là một sự “thoả hiệp” (trade-off) giữa hai giá trị “bias” và “variance” của hai thuật toán MC và “Q-learning”. Thuật toán MC sử dụng một ước lượng không chệch nên có “bias” bằng không nhưng “variance” (tức phương sai) càng cao; khi đó tổng điểm thưởng của cùng một bộ (S, A) sẽ thay đổi rất nhiều. Khi các giá trị này thay đổi quá nhanh thì mạng nơ-ron sẽ học chậm hơn. Trong khi đó “Q-learning” sử dụng một ước lượng chệch nên có “bias” lớn nhưng phương sai lại nhỏ; khi đó giá trị “bootstrap” của cùng một bộ (S, A) sẽ ít thay đổi trong những lần duyệt đến khác nhau. Tương tự như thuật toán MC, công thức cập nhật bộ trọng số trong (2.13) được thay bằng:

$$\theta_{t+1} = \theta_t - \alpha(R_{t+1} + \gamma \max_a \hat{q}(S_{t+1}, a; \theta) - \hat{q}(S, A; \theta_t)) \nabla_{\theta_t} \hat{q}(S, A; \theta_t) \quad (2.16)$$

Mã giả của thuật toán “Q-learning” với xấp xỉ hàm được trình bày ở (2.1).

Thuật toán 2.1 “Q-learning” kết hợp với xấp xỉ hàm

Đầu vào: Số “episode” cần thực hiện để cập nhật bộ trọng số mạng nơ-ron

Đầu ra: Bộ trọng số θ của mạng nơ-ron

Thao tác:

- 1: Khởi tạo ngẫu nhiên bộ trọng số θ của mạng nơ-ron
 - 2: **repeat**
 - 3: Tương tác với môi trường dựa vào chính sách có hàm giá trị được xấp xỉ bởi $q(\cdot; \theta)$ đến khi kết thúc “episode” để có được tập các mẫu dữ liệu $S_1, A_1, R_2, S_2, A_2, R_3, \dots, S_{T-1}, A_{T-1}, R_T$
 - 4: Chia tập dữ liệu trên thành các “mini-batch” gồm B mẫu dữ liệu có dạng S_i, A_i, R_{i+1}
 - 5: **for** mỗi “mini-batch” của tập dữ liệu **do**
 - 6: Cập nhật θ theo công thức (2.16) cho toàn bộ các phần tử trong “mini-batch”
 - 7: **end for**
 - 8: **until** Thực hiện đủ số “episode”
-

2.2 Kết hợp học tăng cường với học sâu vào bài toán tự động chơi game

Phần này trình bày cách kết hợp thuật toán học tăng cường với học sâu vào bài toán tự động chơi game. Đầu tiên, chúng em sẽ trình bày về cấu trúc mạng “Deep Q-Network” [9] - cấu trúc mạng nơ-ron tích chập kết hợp với mạng nơ-ron truyền thẳng được thiết kế riêng biệt cho bài toán tự động chơi game. Phần tiếp theo trình bày hai kỹ thuật quan trọng giúp tăng tính ổn định của quá trình học. Phần cuối cùng đề cập đến vấn đề “đánh giá quá cao” (overestimation) ảnh hưởng thế nào lên kết quả của hệ thống cũng như cách thức giải quyết vấn đề này.

2.2.1 “Deep Q-Network”

Để có được cấu trúc mạng “Deep Q-Network” [9] hoàn chỉnh và hoạt động tốt cho bài toán tự động chơi game, ta kết hợp thuật toán “Q-learning” với mạng nơ-ron tích chập có cấu trúc phù hợp với bài toán. Trong bài toán tự động chơi game, dữ liệu đầu vào mà hệ thống nhận được từ môi trường tại mỗi thời điểm

là một ảnh RGB có kích thước 210×160 . Ta có thể đưa cả hình ảnh này làm dữ liệu đầu vào cho mạng nơ-ron tích chập; tuy nhiên với kích thước khá lớn như vậy, việc huấn luyện hệ thống sẽ tốn nhiều thời gian. Để tăng tốc độ huấn luyện lên, ta có thể thực hiện việc thu nhỏ (scale) ảnh về kích thước nhỏ hơn. Việc tiền xử lý ảnh bằng cách thu nhỏ có thể làm mất mát thông tin, tuy nhiên thực nghiệm cho thấy hệ thống vẫn có độ chính xác cao.

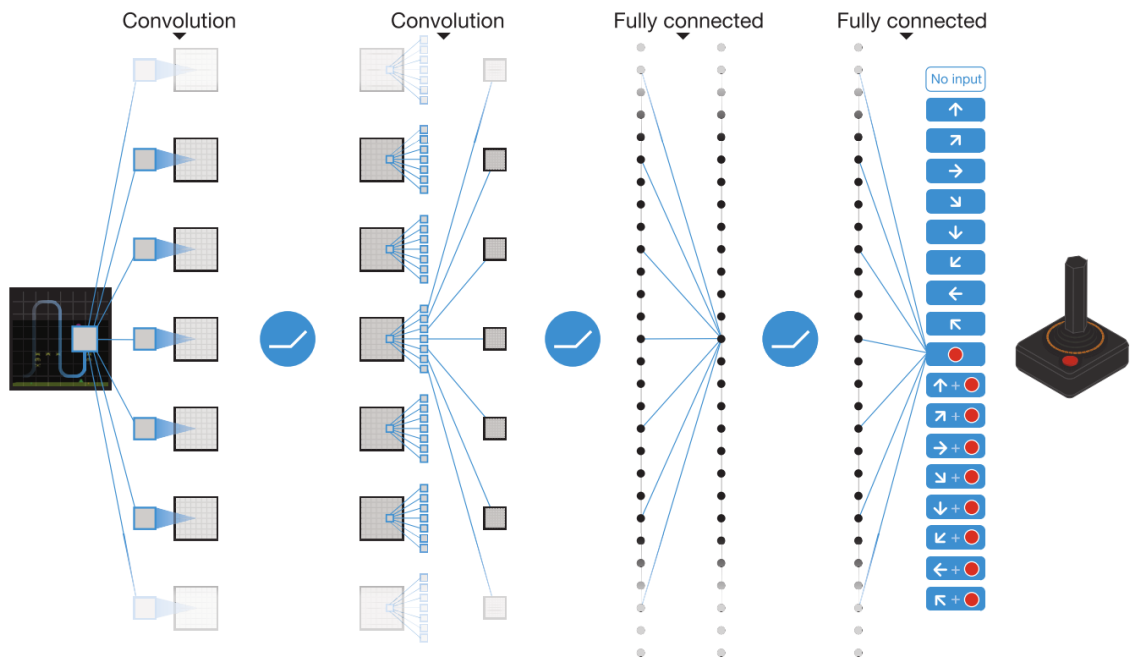
Một điểm quan trọng trong bài toán tự động chơi game là hình ảnh tại mỗi thời điểm không mô tả hết thông tin cần thiết. Ví dụ như khi có hình của một quả bóng, ta không biết hướng và vận tốc hiện tại của quả bóng. Để giải quyết điều này, ta có thể ghép hình ảnh của nhiều thời điểm liên tiếp lại theo thứ tự thời gian. Khi đó một trạng thái S_t sẽ gồm nhiều hình ảnh của các thời điểm liên nhau và chứa luôn cả thông tin về thời gian.

Với cách thiết kế mạng nơ-ron thông thường, ta cần cung cấp trạng thái S và hành động A để tính được giá trị xấp xỉ $\hat{q}(S, A; \theta)$. Cách thiết kế này không phù hợp cho thuật toán “Q-learning”: ta cần phải lan truyền tiến nhiều lần để tính giá trị $\max_a \hat{q}(S, a; \theta)$ trong công thức (2.16). Để khắc phục nhược điểm này, ta chỉnh lại cấu trúc mạng để “input” là trạng thái S và “output” là giá trị của mọi hành động tại trạng thái này: $\hat{q}(S, a; \theta), \forall a$. Với cấu trúc này, ta chỉ việc lan truyền tiến một lần và lấy max giá trị “output” của mạng nơ-ron. Như vậy, số nơ-ron của tầng “output” là số lượng hành động có thể có.

Để tổng hợp các đặc trưng được học từ các tầng tích chập, các tầng ẩn cuối cùng của mạng nơ-ron sẽ là các tầng “fully-connected”. Các tầng tích chập có chức năng tìm kiếm các đặc trưng cục bộ cần thiết còn tầng “fully-connected” có nhiệm vụ tổng hợp các đặc trưng đó trên **toàn ảnh**. Tầng “output” cũng là một tầng “fully-connected” với số nơ-ron là số hành động có thể có. Lưu ý là do tầng này trả về kết quả là giá trị của từng hành động nên ta không áp dụng hàm kích hoạt tại đây. Hình (2.5) mô tả cấu trúc mạng “Deep Q-Network”.

2.2.2 Kỹ thuật làm tăng tính ổn định

Đặc điểm của thuật toán “Q-learning” khi áp dụng xấp xỉ hàm đó là thuật toán không chắc sẽ hội tụ [11]. Hội tụ ở đây ý chỉ sau một số bước cập nhật hữu hạn, giá trị hành động của trạng thái sẽ hội tụ về giá trị nhất định. Do đặc điểm này,



Hình 2.5: Hình mô tả cấu trúc mạng “Deep Q-Network” [9]. Hai tầng ẩn đầu tiên là tầng tích chập với hàm kích hoạt “rectified linear”. Tầng ẩn tiếp theo là tầng “fully-connected” có nhiệm vụ tổng hợp đặc trưng trên toàn ảnh của tầng trước. Tầng “output” cũng là tầng “fully-connected” trả về kết quả là giá trị của từng hành động ứng với trạng thái đầu vào. Tầng “output” không có hàm kích hoạt.

nếu ta huấn luyện mạng nơ-ron bằng thuật toán SGD thông thường thì nhiều khả năng “Q-learning” sẽ không hội tụ dẫn đến chính sách tương ứng sẽ không được tốt. Để giải quyết vấn đề này, chúng em áp dụng hai kỹ thuật giúp tăng tính ổn định và khả năng hội tụ: kỹ thuật “Experience replay” [7] và kỹ thuật cố định “Q-target” [8].

“Experience replay”

Thuật toán “Q-learning” kết hợp với xấp xỉ hàm cho phép ta học “online”: sau mỗi bước tương tác với môi trường và nhận được dữ liệu mới, ta có thể cập nhật ngay bộ trọng số mạng nơ-ron. Tuy nhiên, cách học này có thể gây ra vấn đề không hội tụ. Lý do là các mẫu dữ liệu liên tiếp nhau thường có tương quan (correlation) với nhau rất lớn. Ngoài ra, các mẫu dữ liệu phía sau bị ảnh hưởng bởi chính sách (tương ứng với bộ trọng số mạng nơ-ron) ngay trước đó. Ví dụ như chính sách hiện tại là “luôn qua trái” thì các mẫu dữ liệu liên tiếp sẽ lấy từ phân bố “qua trái”. Khi chính sách thay đổi sang “luôn qua phải” thì tất cả các mẫu dữ liệu mới sẽ lấy từ phân bố “qua phải”. Khi các mẫu dữ liệu có tương quan lớn và phân bố dữ liệu thay đổi nhanh thì “Q-learning” sẽ khó hội tụ [9].

Kỹ thuật “experience replay” [7] giải quyết vấn đề này bằng cách lưu trữ lại một tập các mẫu dữ liệu nhận được gần đây nhất. Sau đó, mỗi lần muốn cập nhật bộ trọng số, ta chỉ việc lấy một ngẫu nhiên một “mini-batch” từ tập dữ liệu này để học. Ý tưởng của kỹ thuật này giống như việc ta “gợi nhớ” lại các kinh nghiệm đã có từ trước đó và học lại từ chúng. Cách làm này cũng mang tính “củng cố” lại những kinh nghiệm mà hệ thống học được trong quá khứ. Do việc lấy ngẫu nhiên nên các mẫu dữ liệu trong “mini-batch” sẽ không còn tương quan lớn với nhau. Ngoài ra, việc lưu trữ lại giúp các mẫu dữ liệu có thể được học lại nhiều lần. Điều này giúp hệ thống học được nhiều hơn mà không phải tương tác với môi trường quá nhiều.

Cố định “Q-target”

Mỗi khi mạng nơ-ron được cập nhật bộ trọng số thì chính sách hiện tại sẽ thay đổi. Khi chính sách thay đổi thì hàm q_π mục tiêu cũng thay đổi theo. Thực tế cho thấy, việc thay đổi nhỏ của bộ trọng số sẽ gây ra thay đổi lớn của chính

sách [8]. Để thấy được điều này, ta có thể thay đổi trọng số ở những tầng đầu tiên của mạng nơ-ron. Khi đó, trọng số này sẽ ảnh hưởng dây chuyền đến những tầng sau làm cho “output” của mạng nơ-ron bị thay đổi nhiều. Do vậy, mỗi khi cập nhật bộ trọng số, hàm mục tiêu q_π tại một bộ trạng thái s và hành động a nhiều khả năng sẽ thay đổi lớn. Do giá trị mục tiêu của việc xấp xỉ hàm thay đổi quá nhiều và liên tục, mạng nơ-ron có thể không xấp xỉ được hàm giá trị như ta mong muốn.

Một kỹ thuật được đề xuất bởi [9] có tên **cố định “Q-target”** (fix Q-target) nhằm giải quyết vấn đề này. Thay vì thay đổi giá trị mục tiêu một cách liên tục, ta có thể cố định lại hàm mục tiêu q_π trong một số bước cập nhật trọng số để mạng nơ-ron xấp xỉ tốt hàm này. Sau một khoảng thời gian, ta mới thay đổi hàm mục tiêu thành hàm ứng với chính sách hiện tại. Các lần cập nhật trọng số tiếp theo lại tiếp tục cố gắng xấp xỉ tốt hàm mục tiêu mới. Quá trình này được lặp lại nhiều lần để hàm mục tiêu cuối cùng mà ta có cũng chính là hàm giá trị tối ưu.

Để có cái nhìn trực quan hơn về kỹ thuật này, ta có thể lấy ví dụ về việc xây một căn nhà. Do quá trình thiết kế ban đầu chưa tính trước đến những trường hợp phát sinh (như thiếu vật liệu, thợ không đủ trình độ...) trong lúc xây dựng nên ta phải điều chỉnh thiết kế lại liên tục. Ta có thể vừa xây dựng căn nhà (ứng với việc thay đổi trọng số mạng nơ-ron) vừa điều chỉnh lại thiết kế căn nhà cho phù hợp (ứng với việc thay đổi chính sách mục tiêu). Tuy nhiên, khi thiết kế căn nhà thay đổi quá nhanh và liên tục thì việc xây dựng theo sẽ gặp nhiều khó khăn và có khả năng khi hoàn thành kết quả sẽ không tốt. Kỹ thuật cố định “Q-target” tương tự với việc ta cố gắng xây dựng hoàn tất một phần của căn nhà (tức xấp xỉ tốt hàm giá trị một chính sách cũ) trước khi thay đổi thiết kế. Cứ như vậy, mỗi khi hoàn tất một phần, ta thay đổi thiết kế (ứng với việc thay đổi hàm mục tiêu) rồi lại xây dựng tiếp. Cách làm này giống như tạo dựng một số các “điểm kiểm soát” (checkpoint) với những mục tiêu xác định. Do các “điểm kiểm soát” này cố định nên việc thay đổi kiến trúc căn nhà sẽ không quá nhiều, dẫn đến quá trình xây dựng sẽ dễ dàng đạt được mục tiêu hơn.

Tuy nhiên, kỹ thuật này dẫn đến một vấn đề là ta cần phải thay đổi hàm mục tiêu sau bao nhiêu lần cập nhật trọng số mạng nơ-ron (tức tần suất thay

đổi hàm mục tiêu)? Nếu tần suất quá cao (tức thay đổi hàm quá nhiều) thì kỹ thuật này không mang lại được nhiều hiệu quả. Nếu tần suất quá thấp (tức ít khi thay đổi hàm mục tiêu) thì việc học sẽ rất chậm do ta phải cập nhật trọng số rất nhiều để xấp xỉ một hàm giá trị cũ; khi cập nhật hàm mục tiêu thì chính sách mới chỉ tốt lên một chút so với chính sách cũ. Vì vậy, ta cần phải chọn một giá trị vừa phải, phù hợp với bài toán tự động chơi game.

2.2.3 Vấn đề “đánh giá quá cao” của thuật toán “Q-learning”

Thuật toán “Q-learning” cải tiến từ thuật toán “Sarsa(0)” bằng cách lấy max giá trị các hành động của trạng thái tiếp theo. Nhắc lại công thức cập nhật của “Q-learning” là:

$$\theta_{t+1} = \theta_t - \alpha \left[R_{t+1} + \gamma \max_a \hat{q}(S_{t+1}, a; \theta) - \hat{q}(S, A; \theta_t) \right] \nabla_{\theta_t} \hat{q}(S, A; \theta_t) \quad (2.17)$$

Nhờ việc lấy max mà thuật toán “Q-learning” hội tụ nhanh hơn [11]: ta luôn ước lượng giá trị của trạng thái tiếp theo dựa vào hành động tốt nhất tại đó. Đây có thể hiểu là một cách nhìn “lạc quan” về tương lai: nếu có nhiều trường hợp tốt, xấu khác nhau thì ta luôn giả sử điều tốt nhất sẽ xảy ra. Tuy việc giả sử này có thể không đúng trong mọi tình huống, do các trạng thái tiếp theo sau đó cũng được cập nhật lại giá trị nên thuật toán “Q-learning” vẫn hội tụ chính xác về chính sách tối ưu.

Rõ ràng là cách nhìn “lạc quan” này cũng có điểm xấu: ta sẽ có cái nhìn quá “lạc quan” (optimistic) về tương lai và dễ dẫn đến khả năng đánh giá quá cao (overestimation) giá trị của trạng thái kế tiếp. Nhất là khi áp dụng xấp xỉ hàm, giá trị ước lượng hiện tại của mạng nơ-ron chưa được chính xác. Khi đó nếu mạng nơ-ron ước lượng cao hơn giá trị thật sự thì vấn đề đánh giá quá cao sẽ xảy ra nhiều hơn. Mặc dù vậy, ta vẫn cần đặt ra câu hỏi: liệu việc đánh giá quá cao có gây ảnh hưởng đến kết quả của chính sách cuối cùng hay không? Rõ ràng là nếu tất cả hành động đều bị đánh giá quá cao (ví dụ như tăng một lượng bằng nhau C) thì việc lựa chọn hành động không bị ảnh hưởng (do ta vẫn chọn hành động tốt nhất theo thuật toán greedy). Tuy nhiên, nghiên cứu [?] chỉ ra

rằng thuật toán “Q-learning” với xấp xỉ hàm gặp hiện tượng đánh giá quá cao không đồng đều. Điều này làm cho kết quả của một số bài toán cụ thể bị ảnh hưởng lớn. Trong nghiên cứu này, các tác giả đã giả sử sai số do xấp xỉ hàm là do công cụ xấp xỉ hàm không đủ linh hoạt. Sau đó, nghiên cứu của [5] cho thấy sai số do môi trường gây ra cũng gây ảnh hưởng đến việc xấp xỉ hàm và gây nên hiện tượng đánh giá quá cao. Các nghiên cứu trên đều cho thấy vấn đề này có ảnh hưởng lớn đến chính sách tìm được của thuật toán “Q-learning”.

Để khắc phục vấn đề đánh giá quá cao, thuật toán “Double Q-learning” [5] ra đời và được áp dụng vào bài toán tự động chơi game [14]. Đây là một thuật toán cải tiến của “Q-learning” bằng cách thay đổi lại cách ước lượng giá trị của trạng thái tiếp theo. Cụ thể hơn, giá trị này theo “Q-learning” là:

$$R_{t+1} + \gamma \max_a \hat{q}(S_{t+1}, a; \theta) \quad (2.18)$$

Ta có thể tách việc lấy max giá trị ra thành hai bước: chọn hành động tối ưu và đánh giá hành động đó. Bước chọn hành động được thực hiện bằng cách chọn hành động cho giá trị cao nhất tại trạng thái: $a' = \arg \max_a \hat{q}(S_{t+1}, a; \theta)$. Bước đánh giá hành động được thực hiện bằng cách lấy lại giá trị của hành động tốt nhất: $\hat{q}(S_{t+1}, a'; \theta)$. Ghép hai bước này lại ta có công cách ước lượng giá trị của thuật toán “Q-learning”:

$$R_{t+1} + \gamma \hat{q}(S_{t+1}, \arg \max_a \hat{q}(S_{t+1}, a; \theta); \theta) \quad (2.19)$$


Lưu ý rằng công thức (2.19) chỉ là một cách nhìn khác của công thức (2.18) và hai công thức này hoàn toàn tương đương nhau.

Thuật toán “Double Q-learning” giảm thiểu vấn đề đánh giá quá cao bằng cách đánh giá hành động tốt nhất bằng hàm giá trị của chính sách khác với chính sách hiện tại. Cụ thể hơn, ta cần học hai mạng nơ-ron với hai bộ tham số θ và θ^- . Khi cần cập nhật bộ tham số θ của mạng đầu tiên, ta áp dụng công thức:


$$R_{t+1} + \gamma \hat{q}(S_{t+1}, \arg \max_a \hat{q}(S_{t+1}, a; \theta); \theta^-) \quad (2.20)$$

Công thức trên chỉ khác với công thức (2.19) ở chỗ ta đánh giá hành động

được chọn bằng một mạng nơ-ron khác. Nhờ việc “phân tách” (decouple) hai bước trên, “Double Q-learning” làm giảm khả năng bị đánh giá quá cao mà “Q-learning” gặp phải ([5]). Vậy tại sao cách cập nhật này lại không gặp vấn đề nêu trên? Trong “Q-learning”, ta cần tính max của giá trị của nhiều hành động. Do mỗi giá trị hành động tính được đều là xấp xỉ nên sẽ có sai số nhất định (tức sai số giữa giá trị xấp xỉ và giá trị thực $\hat{q}(s, a; \theta) - q_\pi(s, a)$). Giả sử sai số này là “uniform” trong đoạn $[-\epsilon, \epsilon]$ với ϵ là một giá trị dương nhỏ. Khi lấy max giá trị nhiều hành động lại thì nhiều khả năng hành động được chọn sẽ có sai số dương (do các hành động có sai số âm thì giá trị xấp xỉ bị giảm so với giá trị đúng nên khả năng được chọn thấp hơn). Khi càng có nhiều hành động thì khả năng hành động đó có sai số dương lại càng cao hơn. Điều này làm cho “Q-learning” gặp vấn đề đánh giá quá cao. Trong khi với thuật toán “Double Q-learning”, gọi hành động được chọn theo bộ tham số θ là a_* . Khi đó, xác suất để a_* cũng có sai số dương theo bộ tham số θ^- là thấp (do hai bộ tham số học từ dữ liệu khác nhau). Nhờ vậy, việc phân tách hai bước chọn và đánh giá hành động giúp làm giảm vấn đề đánh giá quá cao. Xem hình (2.6) và (2.7) mô tả một ví dụ đơn giản để hiểu hơn về vấn đề đánh giá quá cao trong hai thuật toán “Q-learning” và “Double Q-learning”.



Hình 2.6: Hình mô tả vấn đề đánh giá quá cao của thuật toán “Q-learning”. Trục hoành thể hiện mười hành động và trục tung thể hiện giá trị tương ứng. Chấm tròn thể hiện giá trị thực sự của từng hành động và các đoạn song song với trục tung thể hiện sai số do quá trình xấp xỉ. Đường thẳng nằm ngang thể hiện max của giá trị thực sự của tất cả các hành động. Đây là giá trị đích mong muốn của “Q-learning”. Có nhiều hành động có giá trị xấp xỉ với sai số dương lớn hơn giá trị đích này (hành động 4, 6 và 8) nên khi lấy max theo “Q-learning” thì ta gặp tình trạng đánh giá quá cao.



Hình 2.7: Hình mô tả cách giải quyết vấn đề đánh giá quá cao của thuật toán “Double Q-learning”. Đồ thị bên trái thể hiện giá trị hành động được xấp xỉ theo bộ tham số θ ; đồ thị bên phải là giá trị hành động theo bộ tham số θ^- . Khi chọn hành động theo bộ tham số θ , nhiều khả năng ta sẽ chọn hành động 4, 6 hoặc 8. Tuy nhiên, theo bộ tham số θ^- thì các hành động này lại không phải là những hành động có giá trị xấp xỉ cao nhất. Nhờ việc lựa chọn và đánh giá hành động một cách độc lập như vậy mà thuật toán “Double Q-learning” không gặp vấn đề đánh giá quá cao.

Chương 3

Kết quả thực nghiệm

Trong chương này, chúng em trình bày kết quả thực nghiệm của bài toán tự động chơi game. Đầu tiên, môi trường giả lập của bài toán tự động chơi game cùng với các thiết lập thực nghiệm được giới thiệu. Phần tiếp theo, chúng em trình bày về kết quả thực nghiệm của thuật toán “Q-learning” để chứng minh tính khả thi của việc kết hợp học tăng cường với học sâu vào bài toán tự động chơi game. Kế tiếp, chúng em phân tích mức độ ảnh hưởng của vấn đề “đánh giá quá cao” và kết quả của thuật toán “Double Q-learning”. Phần cuối cùng bao gồm một số thực nghiệm chứng minh rằng mô hình mạng nơ-ron xấp xỉ tốt hàm giá trị hành động.

3.1 Giới thiệu môi trường thực nghiệm

3.2 Các thiết lập thực nghiệm

Chúng em thực hiện huấn luyện hệ thống trên ba trò chơi: *Assault*, *Breakout* và *Seaquest*. Việc thực nghiệm trên ba trò chơi là để chứng minh hướng tiếp cận kết hợp học sâu với học tăng cường có thể áp dụng vào nhiều trò chơi khác nhau. *Assault* là trò chơi bắn máy bay truyền thống: hệ thống điều khiển máy bay bay qua trái, phải hoặc bắn tên lửa để hạ máy bay địch. *Breakout* là trò chơi “phá gạch”: hệ thống điều khiển một mái chèo (paddle) qua trái, phải để giữ cho trái banh không rơi xuống dưới; phía trên là những viên gạch bị phá huỷ và

cho điểm thưởng khi chạm phải trái banh. Cuối cùng là trò chơi *Sequest* có nội dung tương tự như “Assault” nhưng là điều khiển tàu ngầm theo cả tám hướng xung quanh. Tuy các trò chơi này có nội dung tương tự nhau nhưng luật chơi cụ thể lại rất khác biệt và đòi hỏi chiến thuật mang tính “dài hơi”. Ví dụ như màn hình trò chơi *Sequest* có một thanh không khí thể hiện mức độ không khí còn lại trong tàu ngầm. Khi thanh này cạn thì ta cần điều khiển tàu ngầm nổi lên mặt nước để lấy không khí. Vì vậy, hệ thống cần học được đặc trưng thể hiện mức không khí còn lại và dựa vào đó để điều khiển tàu ngầm nổi lên mặt nước. Ngoài ra, để chơi tốt và đạt nhiều điểm, hệ thống cần học được chiến thuật đợi không khí còn lại ít nhất rồi mới nổi lên mặt nước một lần để tiết kiệm thời gian. Ví dụ này cho thấy các trò chơi này đều đòi hỏi các đặc trưng học được phải rất trừu tượng và chiến thuật chơi cũng phải khá phức tạp. Hình () thể hiện màn hình một khung ảnh của ba trò chơi trên.

Để giảm bớt tính toán của mô hình, khung ảnh RGB đầu vào được chuyển về ảnh mức xám (grayscale) và được giảm kích thước về 84×84 . Để lưu thông tin về sự di chuyển và tốc độ của các đối tượng trong ảnh, ta ghép bốn khung ảnh liên tiếp nhau lại thành một trạng thái. Vậy một trạng thái lúc này sẽ gồm bốn ảnh mức xám 84×84 và được đưa trực tiếp vào “input” của mạng nơ-ron. Ngoài ra, do các khung hình gần nhau thường không thay đổi nhiều, một kỹ thuật đơn giản để tăng tốc độ huấn luyện đó là ta lặp lại một hành động cho k khung hình liên tiếp. Nhờ kỹ thuật này, ta có thể huấn luyện nhiều hơn k lần so với khi không áp dụng. Trong thực nghiệm này, chúng em chọn k bằng 4 theo đề xuất của ([8]).

Cấu trúc mạng nơ-ron tích chập được dùng để xấp xỉ hàm giá trị là “Deep Q-Network” ([9]). Mạng này bao gồm bốn tầng ẩn với ba tầng đầu là tầng tích chập và tầng cuối là tầng “Fully-connected”. Tầng tích chập đầu tiên gồm 32 bộ lọc với kích thước 8×8 và bước dịch chuyển (stride) là 4×4 . Tầng tích chập thứ hai gồm 64 bộ lọc với kích thước 4×4 và bước dịch chuyển là 2×2 . Tầng tích chập cuối cùng gồm 64 bộ lọc với kích thước 3×3 và bước dịch chuyển là 1×1 . Đầu ra của tầng tích chập được đưa vào một tầng “Fully-connected” gồm 512 nơ-ron ẩn để tổng hợp đặc trưng. Tầng “output” của mạng cũng là một tầng “Fully-connected” với số nơ-ron ẩn là số hành động của trò chơi (6 cho “Assault”,

4 cho “Breakout” và 18 cho “Seaquest”). Tầng này sẽ trả về giá trị hành động tương ứng cho trạng thái đầu vào. Hàm kích hoạt của tất cả các tầng ẩn là hàm “Rectified”: $\sigma(x) = \max(0, x)$.

Để huấn luyện mạng nơ-ron này, chúng em áp dụng thuật toán “RMSprop” ([13]) để tối thiểu hàm lỗi bình phương. Đây là một thuật toán cải tiến của SGD với ý tưởng chọn một hệ số học khác nhau cho từng trọng số của mạng nơ-ron. Hệ số học của mỗi trọng số sẽ phụ thuộc vào giá trị đạo hàm của hàm lỗi đối với trọng số này ở các bước cập nhật trước. Cụ thể hơn, nếu trọng số này được cập nhật ít ở những lần cập nhật trước thì hệ số học sẽ được tăng lên; trọng số được cập nhật nhiều thì sẽ có hệ số học giảm đi. Nhờ thuật toán này mà mức độ thay đổi của các trọng số là tương đương nhau.

Chúng em sử dụng “Python” (kết hợp với framework “Theano” ([12])) làm ngôn ngữ lập trình chính. Do việc huấn luyện đòi hỏi sức mạnh tính toán rất lớn nên chúng em thực hiện cài đặt tính toán song song trên GPU để tăng tốc. GPU được dùng là NVIDIA GTX 980.

Với các thiết lập thực nghiệm trên, chúng em tiến hành huấn luyện ba trò chơi với hai thuật toán “Q-learning” và “Double Q-learning”. Mỗi trò chơi với mỗi thuật toán được huấn luyện 50 triệu hành động. Thời gian huấn luyện là khoảng 50 giờ cho mỗi trò chơi với mỗi thuật toán.

3.3 Thuật toán “Q-learning”


Để thực nghiệm khả năng học và tự động chơi game, chúng em thực hiện thử nghiệm thuật toán “Q-learning” kết hợp với học sâu. Chúng em sử dụng chính sách ϵ -greedy để làm chính sách khám phá không gian trạng thái và không gian hành động. ϵ -greedy được chọn ở đây là vì chính sách này đơn giản cho việc cài đặt mà vẫn đảm bảo khả năng khám phá không gian cũng như khai thác kiến thức đã học của mô hình. Do ban đầu hệ thống chưa có nhiều hiểu biết về môi trường, chúng ta nên khám phá nhiều hơn; sau khi có một số hiểu biết nhất định thì hệ thống lại cần khai thác những hiểu biết đó. Ý tưởng này có thể dễ dàng được cài đặt bằng cách giảm dần hệ số ϵ trong khi đang huấn luyện. Với thuật toán “Q-learning”, chúng em thực hiện giảm dần ϵ từ 1.0 về 0.1 trong 1

triệu hành động đầu tiên.

Để tiện cho việc quan sát kết quả và thử nghiệm hệ thống, chúng em chia quá trình huấn luyện 50 triệu hành động ra thành 200 “epoch” (tức mỗi “epoch” bao gồm 250000 hành động). Sau mỗi “epoch”, chúng em kiểm thử bộ trọng số học được trên 30 màn chơi và lưu lại điểm số trung bình. Kết quả điểm số cuối cùng được báo cáo của mỗi trò chơi là giá trị điểm số lớn nhất của 200 epoch. Các thiết lập trên tương đồng với ([9]) để việc so sánh là công bằng nhất.

Một đặc điểm của bài toán tự động chơi game đó là kết quả điểm thưởng sau từng “epoch” thường rất nhiều. Giá trị của các trọng số mạng nơ-ron có thể thay đổi ít sau mỗi “epoch” nhưng hàm giá trị tương ứng sẽ thay đổi nhiều. Điều này dẫn đến chính sách tương ứng cũng thay đổi nhiều làm cho điểm thưởng nhận được khi chơi game của các chính sách này sẽ rất khác nhau. Vì vậy nếu ta chỉ quan sát đồ thị điểm thưởng của quá trình kiểm thử sau mỗi “epoch”, ta sẽ không biết chắc là hệ thống có đang chơi tốt lên hơn không. Một cách khác để quan sát quá trình học được đề xuất bởi ([8]) đó là ta quan sát đồ thị giá trị của một tập trạng thái sau từng “epoch”. Đầu tiên, ta thực hiện chơi game một cách ngẫu nhiên và lưu lại một tập các trạng thái gặp được trong quá trình chơi này (gọi là tập “hold-out”). Trong quá trình huấn luyện, sau mỗi “epoch”, ta tính trung bình giá trị hành động tốt nhất của các trạng thái trong tập “hold-out”. Một chính sách chơi tốt thì thường sẽ đánh giá các hành động của các trạng thái trong tập “hold-out” cao hơn so với các chính sách chơi không tốt. Vì vậy, quan sát đồ thị này là một cách đơn giản để theo dõi quá trình học của hệ thống.

Hình (3.1) thể hiện đồ thị điểm số và giá trị trạng thái trên tập “hold-out” của trò chơi *Assault*. Điểm thưởng kết quả của ba game được báo cáo trong bảng (3.1). Cả ba game được thực nghiệm cho kết quả vượt xa kết quả chơi ngẫu nhiên. Điều này cho thấy hệ thống thật sự học được cách chơi để đạt được nhiều điểm số dù ban đầu không hề biết quy luật chơi. Hai trong số ba game còn cho kết quả hơn cả kết quả do con người chơi. Tuy nhiên, bài báo [9] chỉ cho người chơi học thử khoảng 2 giờ cho mỗi game, ít hơn nhiều so với việc huấn luyện 50 triệu hành động (tức khoảng 38 ngày chơi) của hệ thống. Vì vậy, điểm thưởng nhận được của con người trong bảng (3.1) chỉ mang tính tham khảo. Dù chúng em thực hiện cài đặt lại thuật toán được đề xuất bởi bài báo [9] nhưng



Hình 3.1: Đồ thị kết quả của trò chơi *Assault*. Đồ thị ở trên thể hiện trung bình giá trị hành động trên tập “hold-out” theo “epoch” huấn luyện; đồ thị ở dưới thể hiện điểm thưởng trung bình theo “epoch” huấn luyện. Điểm thưởng trung bình thay đổi rất nhiều sau từng “epoch”. Nếu sử dụng đồ thị này để theo dõi quá trình huấn luyện thì ta sẽ không biết là hệ thống có đang học được cách chơi game hay không. Trong khi đó, đồ thị giá trị hành động lại ít nhiễu hơn và hội tụ dần đến một mức nhất định. Quan sát đồ thị này, ta thấy những “epoch” đầu hệ thống học rất nhanh và sau khoảng 50 “epoch” thì giá trị hành động không tăng cao hơn nữa. Lúc này, ta có thể dừng việc học sớm. Tuy nhiên, một số game có thể cần học lâu hơn. Vì vậy, chúng em cố định số “epoch” để huấn luyện được nhiều trò chơi mà không phải thay đổi siêu tham số.

Bảng 3.1: Kết quả *Ngẫu nhiên* nhận được bằng cách chơi với chính sách ngẫu nhiên (chọn hành động theo phân bố đều). Kết quả *Con người* nhận được bằng cách cho một số người học và chơi các game này. *Kết quả gốc* là kết quả thực nghiệm của bài báo [9]. Kết quả *Thực nghiệm* là kết quả do nhóm thực hiện cài đặt lại thuật toán “Q-learning”. Giá trị được in đậm là giá trị lớn nhất của mỗi dòng.

	<i>Ngẫu nhiên</i> [9]	<i>Con người</i> [9]	<i>Kết quả gốc</i> [9]	<i>Thực nghiệm</i>
<i>Assault</i>	222.4	742.0	4,280.4	3,078.8
<i>Breakout</i>	1.7	30.5	385.5	377.6
<i>Seaquest</i>	68.4	42,054.7	5,860.6	6,340.7

kết quả cũng không bằng nhau (cao hơn ở game *Seaquest* và thấp hơn ở hai game còn lại). Lý do chính của điều này là vì cách cài đặt khác nhau và chương trình giả lập game Atari khác nhau.

3.4 Thuật toán “Double Q-learning”

Chúng em thực hiện cài đặt và thử nghiệm lại thuật toán “Double Q-learning” [5], [14] để giải quyết vấn đề đánh giá quá cao. Các thiết lập thực nghiệm đều giống như khi thực nghiệm thuật toán “Q-learning”. Tuy nhiên, để tương đồng với cài đặt của bài báo [14], chúng em giảm hệ số ϵ từ 1.0 xuống 0.01 (thay vì 0.1 như ở phần thực nghiệm “Q-learning”) trong 1 triệu hành động đầu tiên của quá trình huấn luyện.


Bảng 3.2 cho biết kết quả của thuật toán “Double Q-learning” trên ba game. Thuật toán “Double Q-learning” cho kết quả tốt hơn hẳn điểm số của “Q-

Bảng 3.2: Kết quả *Ngẫu nhiên* và *Con người* được trích từ bài báo [14]. Do môi trường giả lập game khác nhau nên chúng em chỉ so sánh “Double Q-learning” với phiên bản cài đặt “Q-learning” của nhóm thay vì so sánh với phiên bản “Double Q-learning” của bài báo [14]. Giá trị được in đậm là giá trị lớn nhất của mỗi dòng.

	<i>Ngẫu nhiên</i> [9]	<i>Con người</i> [9]	<i>Q-learning</i>	<i>Double Q-learning</i>
<i>Assault</i>	222.4	742.0	3,078.8	4864.6
<i>Breakout</i>	1.7	30.5	377.6	431.2
<i>Seaquest</i>	68.4	42,054.7	6,340.7	13,186

learning” trên cả ba game và cao hơn gấp đôi ở game *Seaquest*. Lý do “Double Q-learning” hoạt động tốt như vậy trên game *Seaquest* là vì game này có nhiều hành động (18 so với 4 của *Breakout* và 6 của *Assault*). Số lượng hành động càng nhiều thì khả năng bị đánh giá quá cao lại càng tăng. Vì vậy, thuật toán “Q-learning” bị ảnh hưởng rất lớn bởi vấn đề đánh giá quá cao và thuật toán “Double Q-learning” cho kết quả tốt hơn hẳn khi giải quyết được vấn đề này. Các kết quả này cho thấy thuật toán “Double Q-learning” là một cải tiến rất tốt cho bài toán tự động chơi game.

Để thấy rõ hơn việc hạn chế vấn đề đánh giá quá cao của “Double Q-learning”, ta có thể coi đồ thị giá trị hành động trung bình trên tập “hold-out” và đồ thị điểm thưởng trung bình của cả hai thuật toán ở hình (3.2). Thuật toán “Double Q-learning” cho kết quả điểm thưởng tốt hơn hẳn “Q-learning” vì đánh giá hành động chính xác hơn (không bị vấn đề đánh giá quá cao).



Hình 3.2: Đồ thị kết quả của trò chơi *Seaquest*. Hình phía trên là đồ thị giá trị hành động trung bình theo “epoch”; hình phía dưới là đồ thị điểm thưởng trung bình theo “epoch”. Ở đồ thị phía trên, thuật toán “Q-learning” đánh giá rất cao các hành động của trạng thái thuộc tập “hold-out”. Tuy nhiên, khi chơi thử game thì thuật toán “Q-learning” lại cho điểm thưởng rất thấp. Điều này cho thấy thuật toán “Q-learning” gặp vấn đề đánh giá quá cao và vấn đề này ảnh hưởng đến kết quả chơi game của hệ thống. Trong khi đó, thuật toán “Double Q-learning” tuy đánh giá các hành động của trạng thái thuộc tập “hold-out” thấp hơn nhưng khi chơi game thì lại được nhiều điểm thưởng hơn. Thuật toán “Double Q-learning” đánh giá chính xác hơn giá trị hành động và vì thế, chính sách chơi game cũng tốt hơn.

3.5 Phân tích hàm giá trị hành động

Để thấy rõ hơn khả năng xấp xỉ hàm giá trị của mạng nơ-ron, ta có thể xem xét giá trị của một số trạng thái trong quá trình chơi game. Cụ thể hơn, chúng em thực hiện lưu một số “frame” ảnh trong quá trình chơi cùng với giá trị của chúng được tính từ mạng nơ-ron (với thuật toán “Q-learning”).

Hình 3.3 và đồ thị 3.4 thể hiện các “frame” ảnh và giá trị của các trạng thái tương ứng. Quan sát giá trị tương đối của các trạng thái liên tiếp nhau trong một lần chơi, ta có thể thấy mạng nơ-ron học được một hàm giá trị phức tạp và có ý nghĩa cao. Nhờ hàm giá trị được xấp xỉ tốt, chính sách chơi game mới lựa chọn hành động hợp lý để nhận được điểm thưởng cao nhất có thể.



(a)



(b)




(c)



(d)

Hình 3.3: Hình ảnh 4 “frame” của trò chơi *Seaquest*. Ở “frame” đầu tiên (hình 3.3a), tàu ngầm do hệ thống điều khiển ở giữa và tàu ngầm địch ở bên phải. Ở “frame” kế tiếp (hình 3.3b), hệ thống thực hiện hành động phóng ngư lôi. Tiếp đó (hình 3.3c), ngư lôi trúng tàu ngầm địch. Cuối cùng (hình 3.3d), tàu ngầm địch bị phá huỷ cho điểm thưởng. Các “frame” này ứng với các giá trị trong đồ thị ở hình 3.4.



Hình 3.4: Đồ thị thể hiện giá trị hành động lớn nhất tại một số trạng thái; các trạng thái này ứng với các “frame” trò chơi *Seaquest*. Tại “frame” được đánh dấu A, giá trị hành động lớn nhất đang ở mức trung bình ứng với việc tàu ngầm của ta chưa thực hiện hành động gì ảnh hưởng đến điểm số. Tại “frame” B, tàu ngầm của ta bắn ngư lôi về phía tàu ngầm địch. Mạng nơ-ron khi nhận được “frame” ảnh này “hiểu” được rằng nếu ngư lôi chạm vào địch thì ta sẽ nhận được điểm thưởng. Vì vậy, đồ thị giá trị bắt đầu tăng lên đến “frame” C. Tại “frame” C, ngư lôi trúng tàu ngầm địch nên việc nhận được điểm là chắc chắn; hàm giá trị biết được điều này nên đồ thị giá trị đạt đỉnh điểm tại đây. Sau khi nhận được điểm thưởng và tàu ngầm địch bị phá hủy, mạng nơ-ron nhận thấy rằng xung quanh không có yếu tố nào có thể giúp tăng điểm số nên đánh giá “frame” D có giá trị thấp.

Chương 4

Kết luận và hướng phát triển

TÀI LIỆU THAM KHẢO

- [1] M. Bellemare, J. Veness, and M. Bowling, “Bayesian learning of recursively factored environments,” in *Proceedings of the 30th International Conference on Machine Learning (ICML-13)*, 2013, pp. 1211–1219. 4
- [2] M. Bellemare, J. Veness, and E. Talvitie, “Skip context tree switching,” in *Proceedings of the 31st International Conference on Machine Learning (ICML-14)*, T. Jebara and E. P. Xing, Eds. JMLR Workshop and Conference Proceedings, 2014, pp. 1458–1466. [Online]. Available: <http://jmlr.org/proceedings/papers/v32/bellemare14.pdf> 4
- [3] I. G. Y. Bengio and A. Courville, “Deep learning,” 2016, book in preparation for MIT Press. [Online]. Available: <http://www.deeplearningbook.org> 9
- [4] M. Genesereth, N. Love, and B. Pell, “General game playing: Overview of the aaai competition,” *AI magazine*, vol. 26, no. 2, p. 62, 2005. 4
- [5] H. V. Hasselt, “Double q-learning,” in *Advances in Neural Information Processing Systems*, 2010, pp. 2613–2621. 27, 28, 36
- [6] M. Hausknecht, J. Lehman, R. Miikkulainen, and P. Stone, “A neuroevolution approach to general atari game playing,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 4, pp. 355–366, 2014. 4
- [7] L.-J. Lin, “Reinforcement learning for robots using neural networks,” DTIC Document, Tech. Rep., 1993. 24

- [8] V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, and M. Riedmiller, “Playing atari with deep reinforcement learning,” *arXiv preprint arXiv:1312.5602*, 2013. [24](#), [25](#), [32](#), [34](#)
- [9] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, “Human-level control through deep reinforcement learning,” *Nature*, pp. 529–533, 2015. [5](#), [21](#), [23](#), [24](#), [25](#), [32](#), [34](#), [36](#)
- [10] S. Risi and J. Togelius, “Neuroevolution in games: State of the art and open challenges,” 2014. [4](#)
- [11] R. S. Sutton and A. G. Barto, *Introduction to reinforcement learning*. MIT Press Cambridge, 1998, vol. 135. [7](#), [22](#), [26](#)
- [12] Theano Development Team, “Theano: A Python framework for fast computation of mathematical expressions,” *arXiv e-prints*, vol. abs/1605.02688, May 2016. [Online]. Available: <http://arxiv.org/abs/1605.02688> [33](#)
- [13] T. Tieleman and G. Hinton, “Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude,” *COURSERA: Neural Networks for Machine Learning*, vol. 4, p. 2, 2012. [33](#)
- [14] H. Van Hasselt, A. Guez, and D. Silver, “Deep reinforcement learning with double q-learning,” *arXiv preprint arXiv:1509.06461*, 2015. [27](#), [36](#)